生物資訊與計算分子生物學

Graph Data (Biological Networks) - 基於 GAE 的酵母菌 PPI 預測模型

組別: 第四組
組員: 吳秉蓉 方安政 張芳樾

目錄

- 資料前處理
- GAE模型設計與訓練
- 邊預測與信心輸出
- 高信心邊視覺化與社群偵測
- String資料庫驗證
- 社群間交互強度與階層分析
- GO & KEGG Enrichment
- 總結

資料前處理

資料集

- 資料來源:Kaggle Protein Protein Interactions Networks
- 網址:https://www.kaggle.com/datasets/alexandervc/protein-protein-interactions/code?datasetId=1237956
- BIOGRID 資料庫
- 資料大小:759348 rows * 37 columns

#BioGRID Interaction ID	Experimental System	Experimental System Type	Author	Publication Source	Organism ID Interactor A	Organism ID Interactor B	Throughput	Source Database	Organism Name Interactor A	Organism Name Interactor B
68770	Affinity Capture-MS	physical	Krogan NJ (2004)	PUBMED:14759368	559292	559292	High Throughput	BIOGRID	Saccharomyces cerevisiae (S288c)	Saccharomyces cerevisiae (S288c)
68771	Affinity Capture-MS	physical	Krogan NJ (2004)	PUBMED:14759368	559292	559292	High Throughput	BIOGRID	Saccharomyces cerevisiae (S288c)	Saccharomyces cerevisiae (S288c)
68774	Affinity Capture-MS	physical	Krogan NJ (2004)	PUBMED:14759368	559292	559292	High Throughput	BIOGRID	Saccharomyces cerevisiae (S288c)	Saccharomyces cerevisiae (S288c)

前處理

- 過濾出只有酵母菌彼此之間的交互作用(Organism ID = 559292)
- 移除重複的蛋白質交互作用(A-B 和 B-A 被視為重複)
- 移除缺失分數的資料(例如:保留 Official Symbol Interactor A/B 與 Score 三個欄位中都不是 NaN 的資料列)

```
edges = df_yeast[['Official Symbol Interactor A', 'Official Symbol Interactor B', 'Score']].dropna()
```

圖結構的建立(利用 NetworkX)

- 初始化一個 networkx.Graph() 物件 G。
- 將每一筆蛋白質互作資料轉換為一條邊加入圖中，格式如下：

```
G = nx.Graph()
for _, row in edges.iterrows():
    G.add_edge(row['Official Symbol Interactor A'], row['Official Symbol Interactor B'], weight=float(row['Score']))
```

其中 weight 屬性代表該互作的可信程度，將用於社群偵測與視覺化強度的依據。

節點特徵計算和正規化

使用的網絡特徵和使用原因:

1. **Degree**:節點與其他節點的連接數。
2. **Clustering coefficient**:衡量局部三角結構密度。
3. **Betweenness centrality**:經常出現在最短路徑上的節點。
4. **Eigenvector centrality**:與高重要節點連接的節點更重要。
5. **K-core number**:節點所屬的最大核心子圖指標。
6. **Closeness centrality**:到所有節點平均距離的倒數。

特徵處理:

- 所有特徵組成一個 shape=(N, 6) 的 numpy array。
- 用 StandardScaler() 進行 Z-score 正規化處理。
- 若有 NaN 值, 轉為 0。

```
deg = dict(G.degree())
clustering = nx.clustering(G)
betweenness = nx.betweenness_centrality(G, k=50, seed=42)
eigen = nx.eigenvector_centrality_numpy(G)
kcore = nx.core_number(G)
closeness = nx.closeness_centrality(G)
features = np.array([
    [deg[i], clustering[i], betweenness[i], eigen[i], kcore[i],closeness[i]]
    for i in G.nodes()
], dtype=np.float32)
features = np.nan_to_num(features, nan=0.0)
features = StandardScaler().fit_transform(features)
```

PyTorch Geometric 資料格式轉換

- 本步驟將 NetworkX 的圖與特徵成功轉換為 PyTorch Geometric 所需的 Data 物件，並透過 RandomLinkSplit 快速完成資料集切分(步驟會將原始圖中的邊切分為訓練、驗證與測試集合)

```
data = from_networkx(G)
data.x = torch.tensor(features, dtype=torch.float)
data.edge_index = to_undirected(data.edge_index)
data.num_nodes = G.number_of_nodes()

transform = RandomLinkSplit(is_undirected=True, split_labels=True, add_negative_train_samples=True)
train_data, val_data, test_data = transform(data)
```

GAE 模型
設計與訓練

模型架構

1. GCNEncoder(圖卷積編碼器)

輸入維度:節點特徵維度 in_channels = 6(因為有 6 種圖特徵)

隱藏層結構:

- 第1層 GCNConv:輸出為 2 × out_channels
- LayerNorm 正規化
- Dropout:以 0.4 機率隨機遮蔽,增強泛化能力
- 第2層 GCNConv:輸出為 out_channels
- LayerNorm 正規化

```python
class GCNEncoder(nn.Module):
    def __init__(self, in_channels, out_channels):
        super().__init__()
        self.conv1 = GCNConv(in_channels, 2 * out_channels)
        self.norm1 = nn.LayerNorm(2 * out_channels)
        self.conv2 = GCNConv(2 * out_channels, out_channels)
        self.norm2 = nn.LayerNorm(out_channels)
        self.dropout = nn.Dropout(0.4)

    def forward(self, x, edge_index):
        x = F.relu(self.norm1(self.conv1(x, edge_index)))
        x = self.dropout(x)
        x = F.relu(self.norm2(self.conv2(x, edge_index)))
        return F.normalize(x, p=2, dim=1)
```

輸出:

- 將每個節點的嵌入向量進行 L2 normalization,使其在單位球面上,便於後續計算 cosine similarity。

模型架構

2. DotDecoder(點積解碼器)

- 接收節點嵌入 z 和欲預測的邊 edge_index。
- 輸出邊對應的內積，代表兩節點間是否可能存在互作的信心分數(越大表示越可能有互作)。

```
class DotDecoder(nn.Module):
    def forward(self, z, edge_index):
        z_i = z[edge_index[0]]
        z_j = z[edge_index[1]]
        return (z_i * z_j).sum(dim=1)
```

模型初始化與優化器設定

- 選擇 **128 維嵌入空間** 作為節點表示。
- 使用 Adam 優化器與小學習率（0.0003）進行穩定訓練。
- **Ranking loss** 損失：要求正樣本信心 > 負樣本信心 + margin（0.2）。

```
in_dim = train_data.x.shape[1]
hidden_dim = 128
...
optimizer = torch.optim.Adam(model.parameters(), lr=0.0003, weight_decay=1e-6)
loss_fn = nn.MarginRankingLoss(margin=0.2)
```

- 若 AUC 指標未提升，則學習率下降一半（factor=0.5），最多忍耐 10 次（patience）

```
scheduler = ReduceLROnPlateau(...)
```

模型訓練與 Early Stopping

```
for epoch in range(1, 301):
    ...
    if wait >= patience:
        print("Early stopping.")
        break
```

```
for epoch in range(1, 301):
    loss = train()
    if epoch % 10 == 0:
```

- 每 10 epoch 進行一次測試集AUC 評估。
- 若 AUC 無提升且 Loss 未低於 0.2，則啟動 early stopping。
- 訓練最長 300 回合，但可提前結束。

新互作預測（Link Prediction）

預測方法說明:

1. 將 z 嵌入向量做 L2 標準化（使 cosine similarity 合理化）。
2. 計算所有節點對的 cosine similarity。
3. 過濾掉訓練集中已知的邊。
4. 將分數從 [-1, 1] 映射到 [0, 1]，作為預測信心。
5. 輸出 `top_k=200` 個最高信心的蛋白質對。

總結：此模型設計的優勢

元件	說明	效益
雙層 GCN 編碼器	探索多階層鄰居結構	增強節點表示學習能力
Ranking Loss	優化相對排序，而非絕對分數	提高邊預測穩定性與 AUC
Cosine Similarity + Normalization	評估邊存在性更合理	確保相似性分數統一尺度
Early Stopping + Scheduler	避免過擬合、自動調整學習率	訓練效率高且穩定
Top-k 策略輸出新互作	控制預測數量、提升生物解釋性	對下游 STRING 分析更友善

邊預測與信心輸出

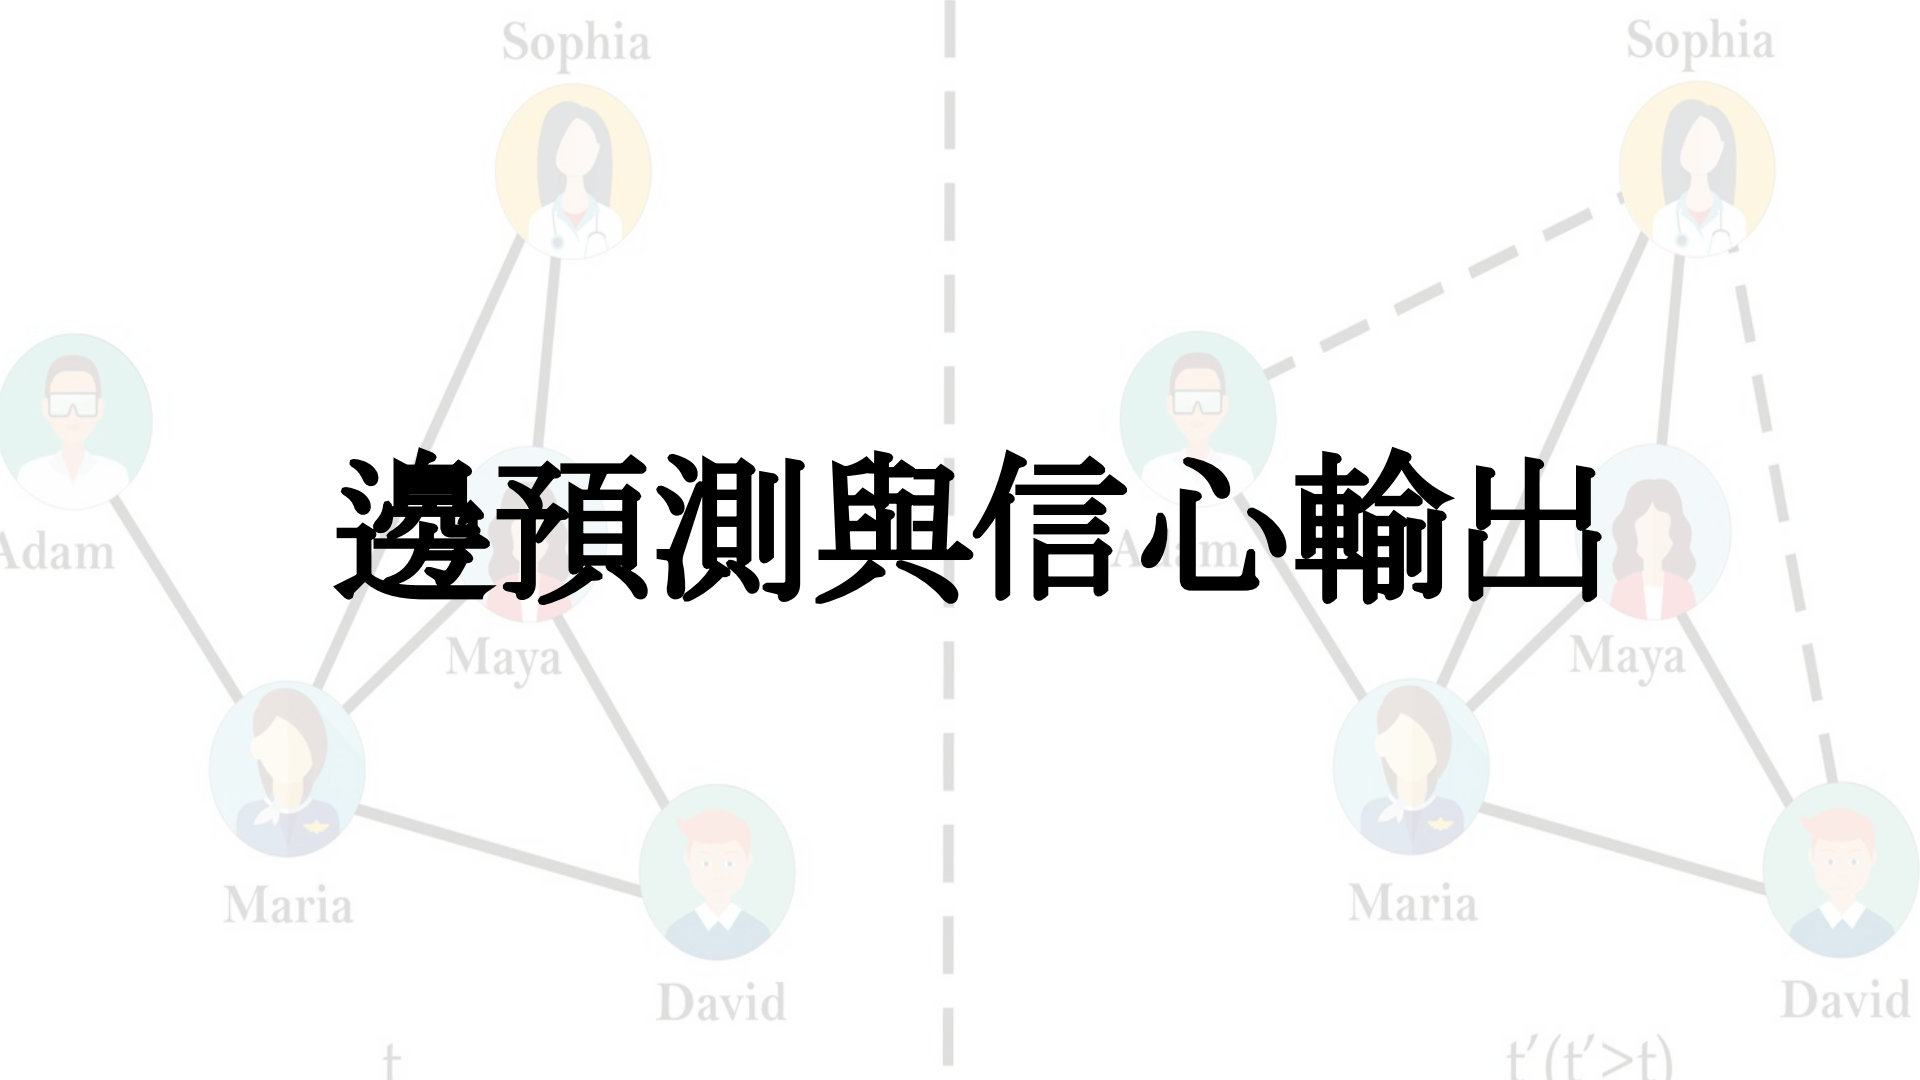
Sophia
Adam
Maya
Maria
David
t
Sophia
Adam
Maya
Maria
David
t′(t′>t)

信心分數分布圖

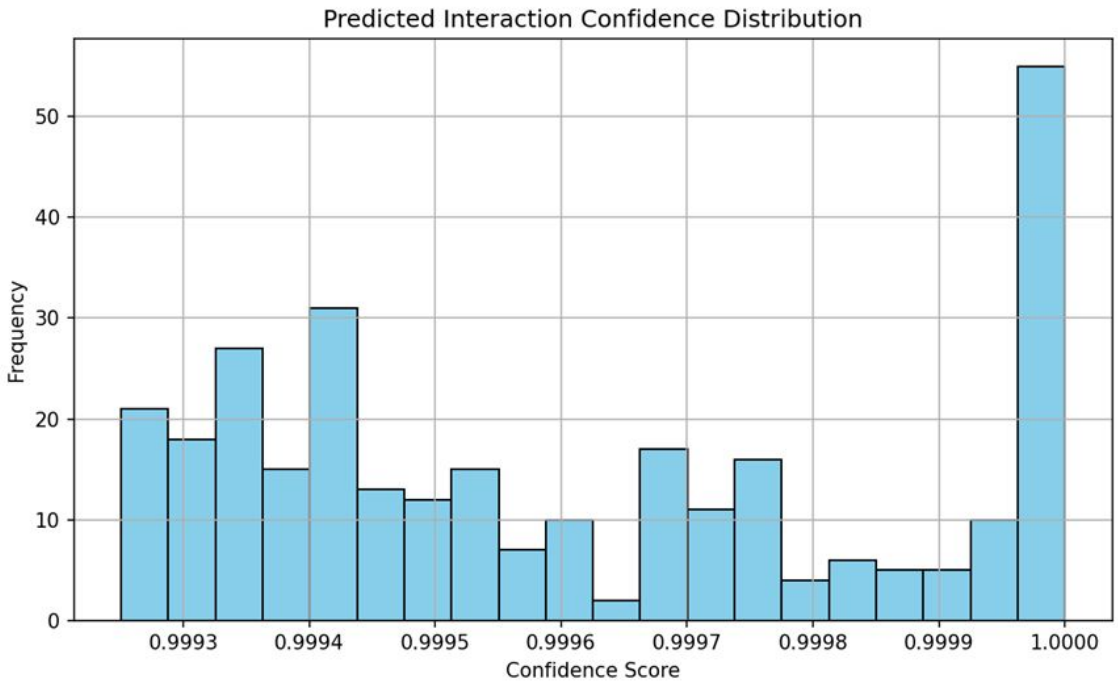

Protein1	Protein2	Confidence
FYV6	MNN9	1
BUD23	SRP14	1
BUD23	RPL30	1
SRP14	RPL30	1
YDR114C	TIM9	1
YDR114C	CUP1-1	1
YDR114C	IMP3	1
YDR114C	SRP21	1
TIM9	CUP1-1	1
TIM9	IMP3	1
TIM9	SRP21	1

高信心邊視覺化
與社群偵測

高分預測交互作用

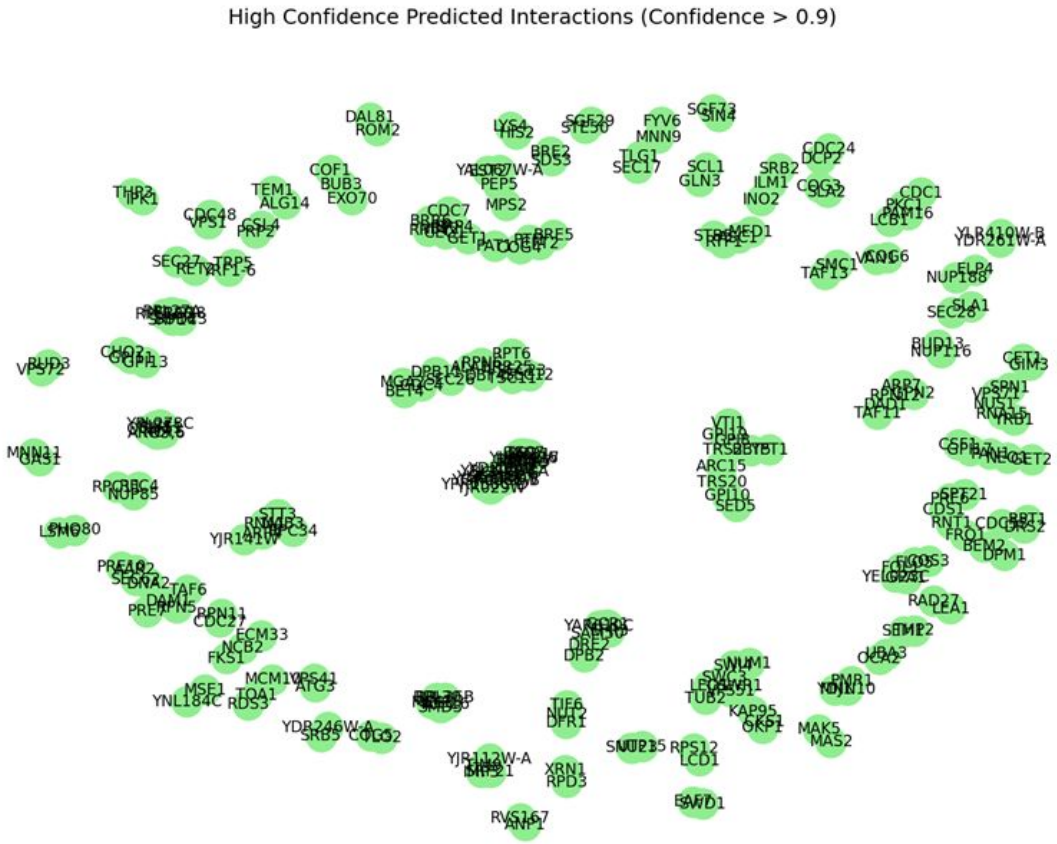

Louvain

- Louvain 演算法是一種社群偵測(community dection)的方法，用來從大型網路中找出社群結構
- 適用於社交網路分析、生物資訊學或其他圖論資料

Louvain

- 篩選出高分預測的交互作用(confidence > 0.9)
- 將每個交互作用的邊加到圖中，邊的權重為 confidence
- 執行 Louvain 社群偵測：將每個蛋白質分到一個社群

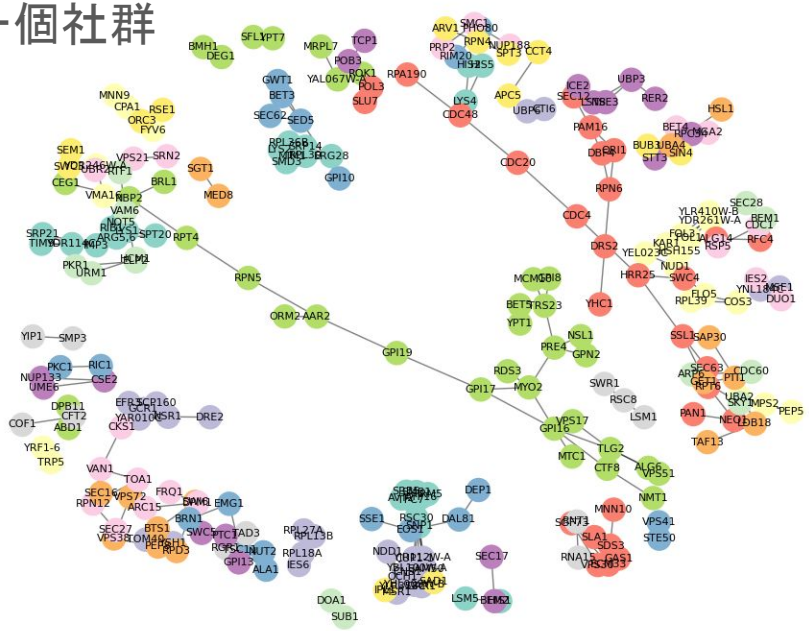

Communities

- 將分類好的社群畫出整個 PPI 網路

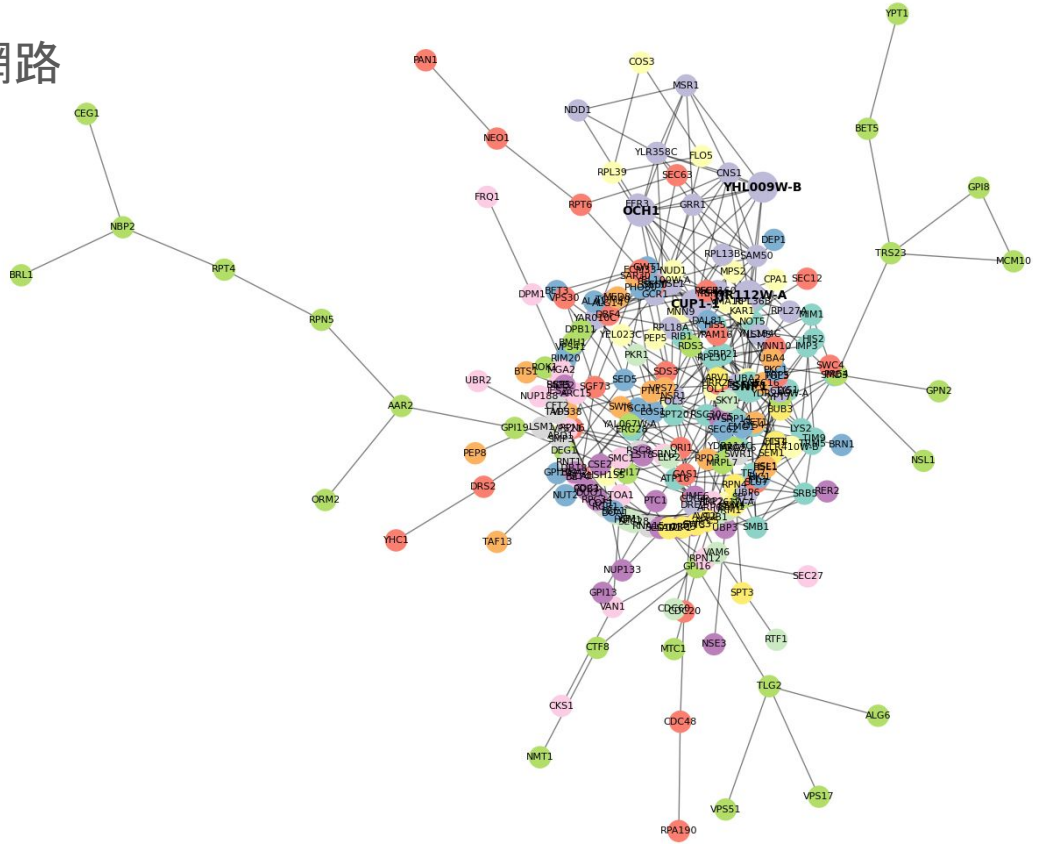

STRING 資料庫驗證

STRING 資料庫介紹

- 用於檢索已知蛋白和預測蛋白之間交互作用的資料庫
- 目前已收錄 12,535 個物種、59,300,000 個蛋白、超過 200 億個交互作用

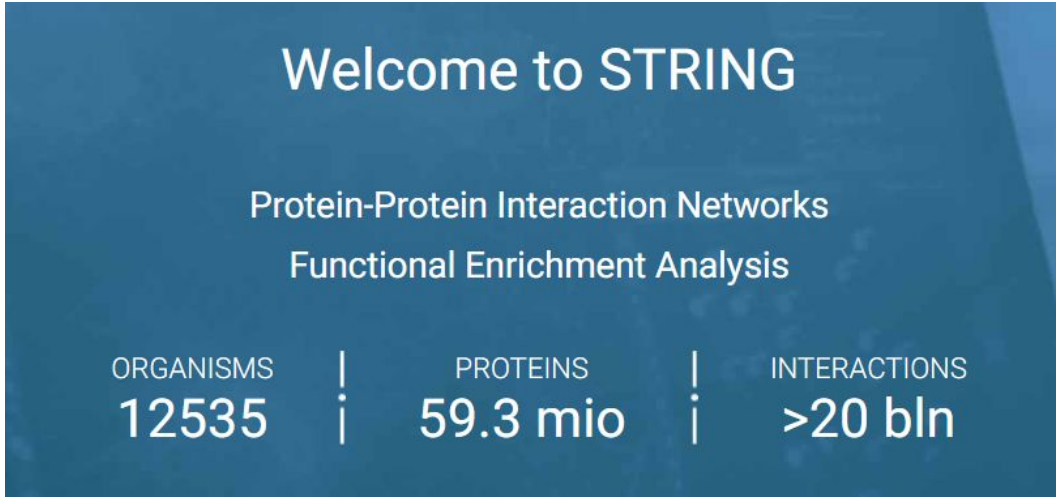

STRING 資料庫

- 使用 STRING 資料庫中的:
  - protein.aliases.v12.0.txt.gz:將蛋白名稱對應到STRING IDs
    - e.g. SRP14 → 4932.YDL092W
  - protein.links.full.v12.0.txt.gz:交互作用的分數
    -

protein1	protein2	combined_score
4932.Q0010	4932.YMR207C	333
4932.Q0010	4932.YCR051W	205
4932.Q0010	4932.YPR002W	195
4932.Q0010	4932.YGR117C	166

- 建立名稱與 ID 的對應表並讀取交互作用的分數

與 GAE 模型預測結果比對

- 載入 GAE 預測結果
- 查詢預測的蛋白的 STRING ID
- 查詢 STRING 分數
- 建立比對的結果，包含 Protein1、Protein2、STRING Score、Match Status

GAE 預測與 STRING 資料庫比對結果

- STRING Match Status:
  - High-confidence: score >= 700
  - Low-confidence: 0 < score < 700
  - Not in STRING: STRING 中沒有交互作用
  - Unmapped: 蛋白未對應到 STRING ID

Protein1	Protein2	Confidence	STRING_Score	Match_Status
SRP14	RPL30	1.000000	930.0	High-confidence
YDR114C	TIM9	1.000000	0.0	Not in STRING
YDR114C	IMP3	1.000000	0.0	Not in STRING
YDR114C	SRP21	1.000000	0.0	Not in STRING
TIM9	IMP3	1.000000	0.0	Not in STRING

GAE 預測與 STRING 資料庫比對結果

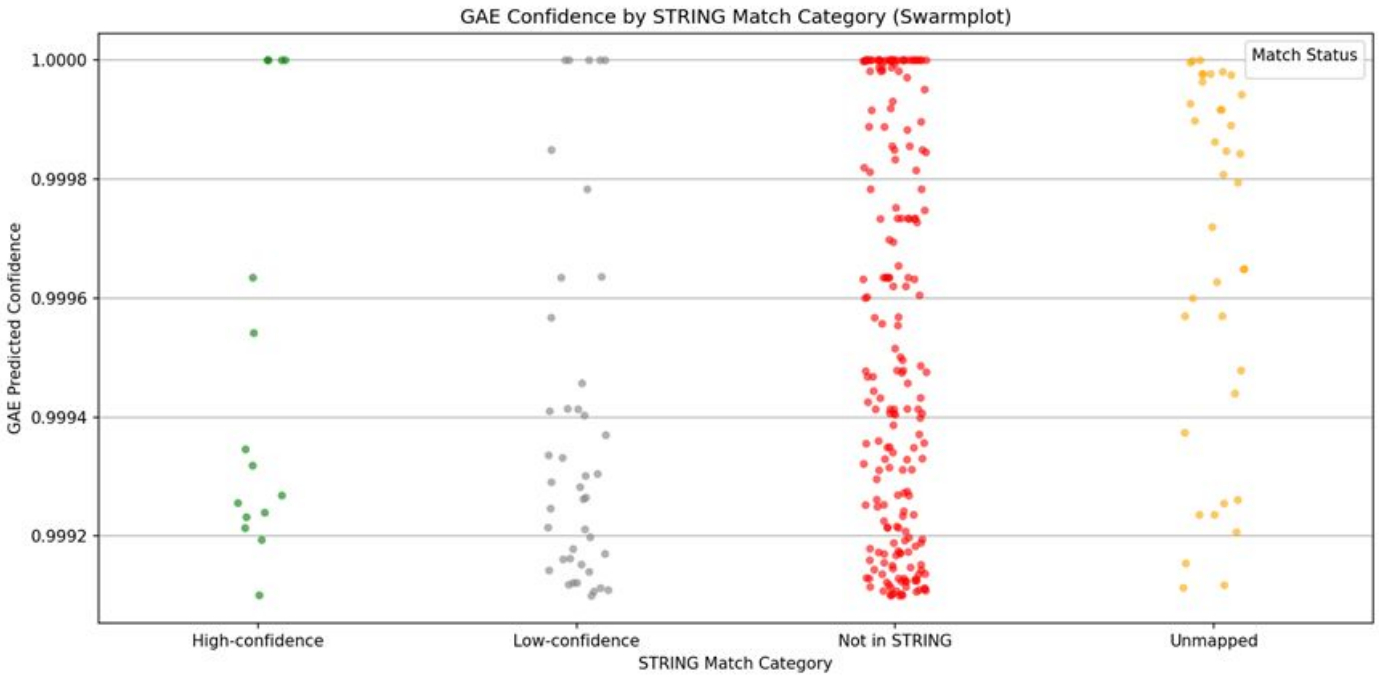

社群間交互強度與階層分析

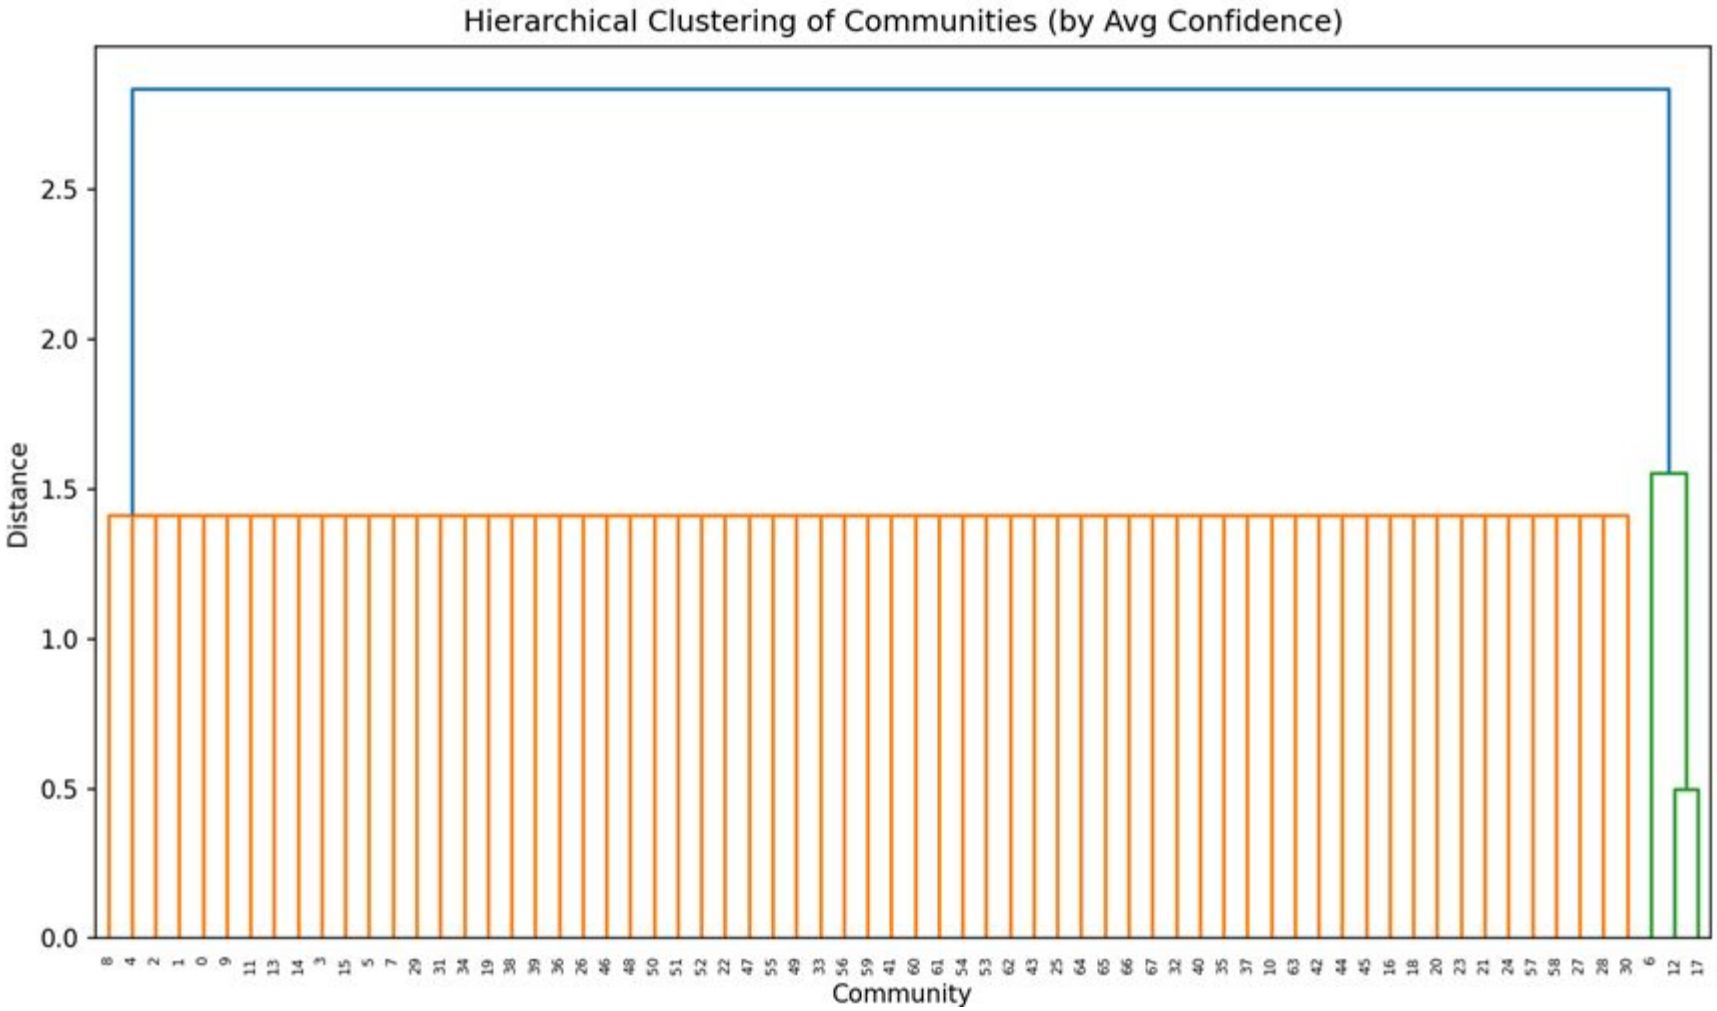
Hierarchical Clustering of Communities (by Avg Confidence)
Distance
2.5
2.0
1.5
1.0
0.5
0.0
8 4 2 1 0 9 11 13 14 3 15 5 7 29 31 34 19 38 39 36 26 46 48 50 51 52 22 47 55 49 33 56 59 41 60 61 54 53 62 43 25 64 65 66 67 32 40 35 37 10 63 42 44 45 16 18 20 23 21 24 57 58 27 28 30 6 12 17
Community

Avg Confidence Heatmap
1.00
0.75
0.50
0.25
0.00
8 2 0 11 14 15 7 31 19 39 26 48 51 22 55 33 59 60 54 62 25 65 67 40 37 63 44 16 20 21 57 27 30 12
Community1

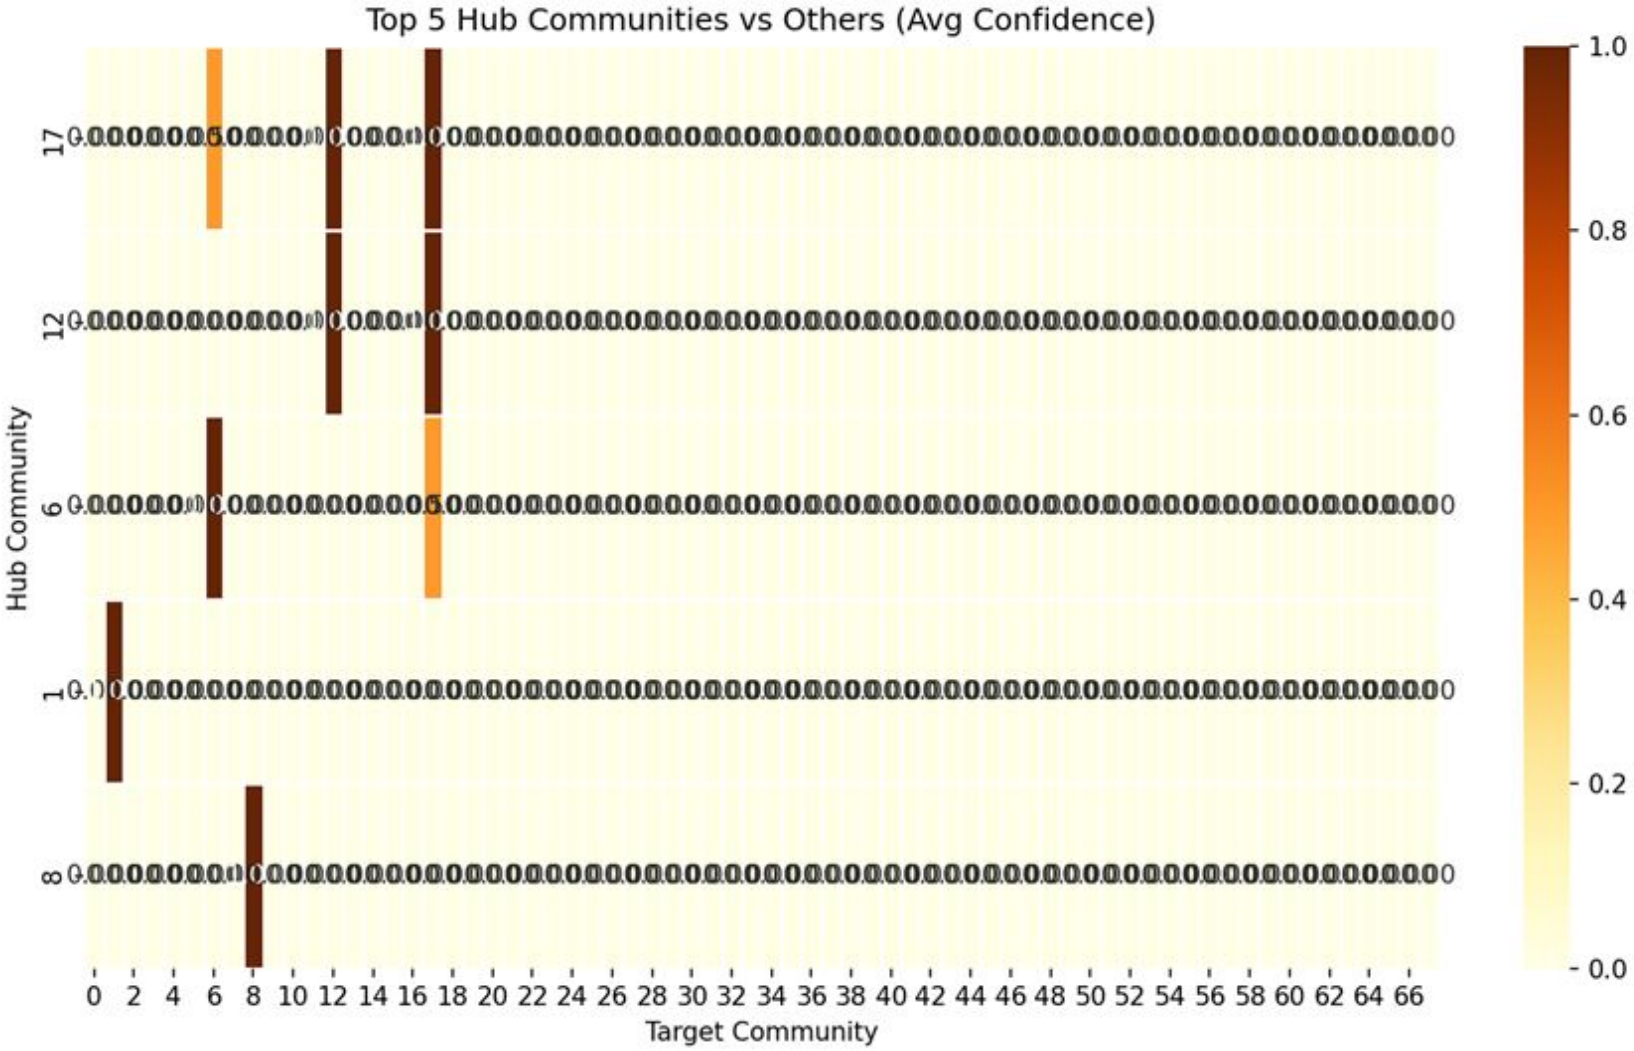
Top 5 Hub Communities vs Others (Avg Confidence)
Hub Community
17
12
6
1
8
Target Community
0 2 4 6 8 10 12 14 16 18 20 22 24 26 28 30 32 34 36 38 40 42 44 46 48 50 52 54 56 58 60 62 64 66
1.0
0.8
0.6
0.4
0.2
0.0

GO & KEGG Enrichment

GO & KEGG Enrichment

- 對蛋白質社群進行 GO 富集分析（GO enrichment analysis）
- 資料前處理：拆分社群
  - e.g. community 0 裡面只有第 0 群的蛋白

SRP14
RPL30
LYS2
SMD3
MIM1
RPL36B
ERG28

community_0.txt
community_1.txt
community_2.txt
community_3.txt
community_4.txt
community_5.txt
community_6.txt
community_7.txt
community_8.txt
community_9.txt
community_10.txt
community_11.txt

GO & KEGG Enrichment

- 使用 g:Profiler API 執行 GO enrichment，支援以下類別
  - GO:BP - 生物過程（Biological Process）
  - GO:MF - 分子功能（Molecular Function）
  - GO:CC - 細胞組成（Cellular Component）
  - KEGG Kyoto Encyclopedia of Genes and Genomes
- 只針對基因數量 >= 5 的社群進行分析

GO & KEGG Enrichment

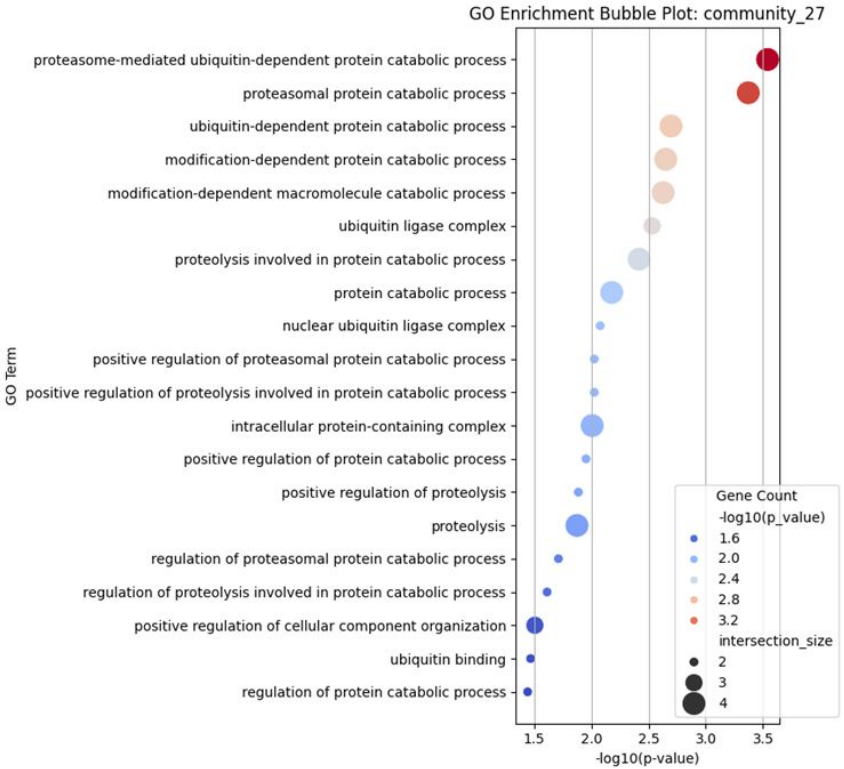

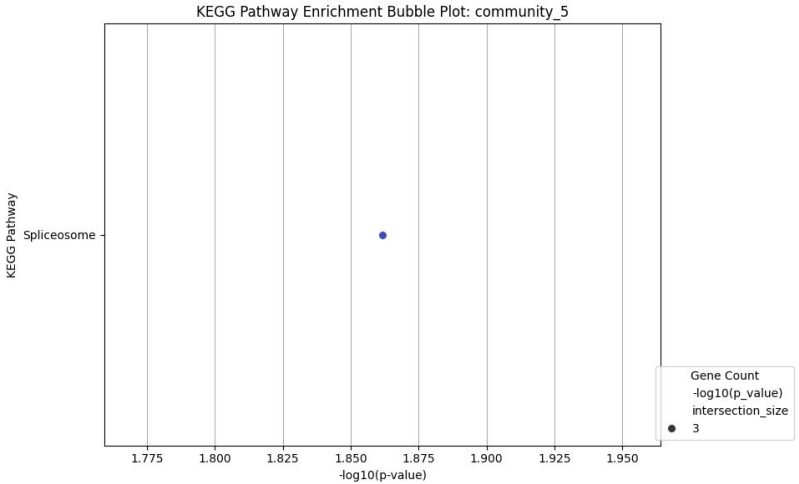

GO & KEGG Enrichment

source	native	name	p_value	significan	descriptio	term_size	query_siz	intersectic	effective_	precision	recall	query	parents
GO:CC	GO:0005685	U1 snRNP	0.0002675	TRUE	"A ribonu	18	11	3	6555	0.27273	0.16667	query_1	['GO:0097525']
GO:CC	GO:0000243	commitment c	0.000503	TRUE	"A splicec	22	11	3	6555	0.27273	0.13636	query_1	['GO:0005684']
GO:CC	GO:0071004	U2-type presp	0.0014562	TRUE	"A splicec	31	11	3	6555	0.27273	0.09677	query_1	['GO:0005684', 'GO:0071010']
GO:CC	GO:0071010	prespliceosom	0.0014562	TRUE	"A splicec	31	11	3	6555	0.27273	0.09677	query_1	['GO:0005681']
GO:BP	GO:0000395	mRNA 5'-spli	0.0020144	TRUE	"Recognit	20	11	3	6510	0.27273	0.15	query_1	['GO:0006376', 'GO:0045292']
GO:BP	GO:0006376	mRNA splice	0.0035633	TRUE	"Selection	24	11	3	6510	0.27273	0.125	query_1	['GO:0000245', 'GO:0022618']
GO:BP	GO:0045292	mRNA cis spl	0.0071082	TRUE	"The joini	30	11	3	6510	0.27273	0.1	query_1	['GO:0000398']
GO:CC	GO:0097525	spliceosomal s	0.0113421	TRUE	"A small r	61	11	3	6555	0.27273	0.04918	query_1	['GO:0030532']
GO:CC	GO:0030532	small nuclear	0.0124918	TRUE	"A ribonu	63	11	3	6555	0.27273	0.04762	query_1	['GO:0120114', 'GO:0140513', 'GO:1990904']
GO:CC	GO:0005684	U2-type splice	0.0130941	TRUE	"Any splic	64	11	3	6555	0.27273	0.04688	query_1	['GO:0005681']
GO:CC	GO:0005687	U4 snRNP	0.0132011	TRUE	"A ribonu	11	11	2	6555	0.18182	0.18182	query_1	['GO:0097525']
KEGG	KEGG:03040	Spliceosome	0.0137503	TRUE	Spliceoso	75	6	3	2161	0.5	0.04	query_1	['KEGG:00000']
GO:CC	GO:0120114	Sm-like protei	0.014355	TRUE	"A protein	66	11	3	6555	0.27273	0.04545	query_1	['GO:0032991']
GO:CC	GO:0005682	U5 snRNP	0.0286708	TRUE	"A ribonu	16	11	2	6555	0.18182	0.125	query_1	['GO:0097525']
GO:BP	GO:0000245	spliceosomal s	0.0357593	TRUE	"The aggr	51	11	3	6510	0.27273	0.05882	query_1	['GO:0000398', 'GO:0022618']
GO:CC	GO:0071001	U4/U6 snRNP	0.0407437	TRUE	"A ribonu	19	11	2	6555	0.18182	0.10526	query_1	['GO:0097525']
GO:CC	GO:0071011	precatalytic sp	0.0407437	TRUE	"A splicec	19	11	2	6555	0.18182	0.10526	query_1	['GO:0005681']
GO:BP	GO:0036261	7-methylguan	0.0464265	TRUE	"Hyperme	9	11	2	6510	0.18182	0.22222	query_1	['GO:0001510', 'GO:0036260']

總結：

- **模型可自動辨識潛在 PPI 並與資料庫整合驗證**

  利用圖自編碼器(GAE)模型進行蛋白質互作預測，可發掘現有資料庫未記載的潛在互作，並與STRING 資料進行比對，驗證模型預測的可信度。

- **透過社群偵測與 GO 富集解析功能性意涵**

  高信心預測結果經 Louvain 社群分析後，配合 GO/KEGG 功能富集，有助於推測互作蛋白可能參與的生物過程與細胞功能模組。

- **探索新穎互作對，支持實驗驗證或假 說生成**

  模型預測但未出現在 STRING 中的蛋白質互作對，可能為新穎交互作用，適合做為後續實驗驗證或提出新的功能假說依據。

- **支援多層級視覺化，有助於網絡解釋**

  流程提供包含互作分數分布、社群結構圖、STRING 比對分類圖與富集泡泡圖等多層級可視化，提升生物網絡的可解釋性與溝通效率。

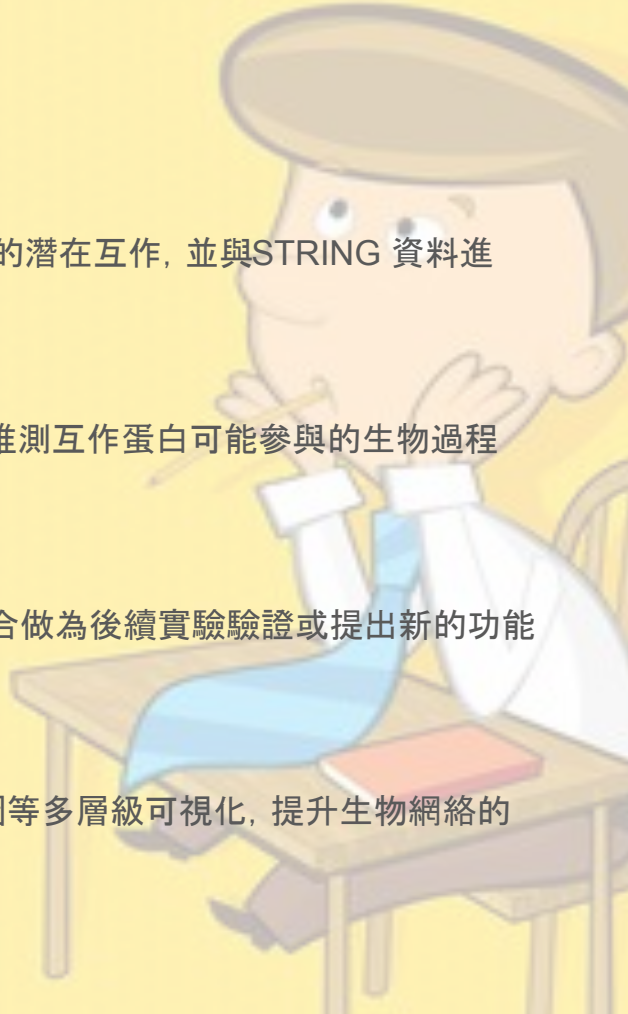

Thank you for your attention